資料分析與機器學習

Midterm Exam. (Date: 20261102)

姓名：_____ 學號：_____

1. B	2. A	3. A	4. C	5. D
6. C	7. A	8. B	9. D	10. D
11. B	12. D	13. C	14. A	15. A
16. B	17. C	18. D	19. C	20. A
21. B	22. A	23. A	24. D	25. C
26. D	27. B	28. C	29. A	30. B
31. C	32. A	33. D	34. B	35. B
36. A	37. B	38. D	39. A	40. D
41. B	42. A	43. C	44. D	45. C
46. A	47. D	48. C	49. D	50. B

單選題 (每題 2 分)

1. **下列何者才是正確的機器學習訓練流程？**
   (A) 先用全資料擬合標準化以獲得最可靠的特徵統計值，再切分資料進行訓練與測試
   (B) 先切分資料，只以訓練集擬合前處理與模型，以測試集評估模型
   (C) 先切分資料，並依據測試結果反覆挑選特徵以得到最佳模型
   (D) 先切分資料，以訓練集選擇模型，再以測試集微調模型

2. **訓練與交叉驗證正確率都偏低且差距小，較符合何種判斷與改善方向？**
   (A) 高偏差，可嘗試增加模型複雜度或降低正則化　(B) 已達到理想效能
   (C) 高變異，必須把模型再簡化　(D) 資料不足，應增加訓練資料

3. **下列何者屬於順序型 (Ordinal) 類別資料？**
   (A) 滿意度 (低、中、高)　(B) 血型 (A、B、AB、O)
   (C) 衣服顏色 (紅、綠、藍)　(D) 性別 (男、女、其他)

4. **預測明天的氣溫數值，通常屬於何種機器學習任務？**
   (A) 分類　(B) 降維　(C)回歸　(D) 分群 (集群)

5. **同一張眼底影像可能同時標示多種疾病，這最符合何種機器學習任務？**
   (A) 互斥多分類　(B) 多目標回歸　(C) 無標籤分群 (集群)　(D) 多標籤分類

6. **損失曲線 (Loss curve)、學習曲線 (Learning curve) 與驗證曲線 (Validation curve) 的橫軸通常分別為何？**
   (A) 訓練輪次、超參數值與訓練資料量　(B) 訓練資料量、訓練輪次與超參數值
   (C) 訓練輪次、訓練資料量與超參數值　(D) 訓練資料量、超參數值與訓練輪次

7. **下列何者屬於可訓練參數 (Trainable Parameters)，而非超參數 (Hyperparameters)？**
   (A) 模型的權重與偏置　(B) 訓練輪次　(C) 批次大小　(D) 學習率

8. **下列關於人工智慧 (AI)、機器學習 (ML) 與 深度學習 (DL) 的關係，何者正確？**
   (A) AI 是 DL 的子領域　(B) ML 是 AI 的子領域，DL 是 ML 的一類方法
   (C) DL 包含所有 AI 方法　(D) ML 與 AI 沒有關係

9. **若感知器 (Perceptron) 的權重與偏置分別為 $\boldsymbol{w} = [w_1, w_2, \ldots, w_m]^T$ 與 b，則 net input z 與輸入特徵 $\boldsymbol{x} = [x_1, x_2, \ldots, x_m]^T$ 的數學關係為何？**
   (A) $z = \boldsymbol{w}(\boldsymbol{x} + b)$　(B) $z = \boldsymbol{w}\boldsymbol{x} + b$　(C) $z = \boldsymbol{w}^T(\boldsymbol{x} + b)$　(D) $z = \boldsymbol{w}^T\boldsymbol{x} + b$

10. **承上題，定義 $z \geq 0$ 預測為 1，否則為 0。若 $\boldsymbol{w} = [2, -2]$、$\boldsymbol{x} = [1,3]$、$b = 0.5$，則預測結果為何？**
    (A) 1，因 $z = 4.5$　(B) 1，因 $z = 3.5$　(C) 0，因 $z = -4$　(D) 0，因 $z = -3.5$

11. **Perceptron Learning Algorithm (PLA) 對某樣本預測正確時，依其更新規則會如何？**
    (A) 只更新偏置　(B) 權重與偏置均不更新　(C) 將所有權重歸零　(D) 只更新權重

12. **一個 Epoch 的意義為何？**
    (A) 只預測一筆測試資料　(B) 只處理一個特徵
    (C) 只進行一次模型初始化　(D) 完整訓練資料集被用於訓練一輪

13. **對 4 個類別的分類問題採用 One-Versus-Rest (OvR) 策略，需建立幾個二元分類器？**
(A) 1 (B) 2 (C) 4 (D) 16

14. **依循 scikit-learn 物件導向式的感知器 API 中，fit(X,y) 方法的主要用途為何？**
(A) 根據訓練資料學習模型參數 (B) 對測試資料進行預測
(C) 繪製決策邊界圖形 (D) 將樣本依據特徵進行標註

15. **Adaline 在學習權重時使用哪一種激活函數 (Activation Function)？**
(A) 恆等函數，即輸出等於 net input (B) Softmax 函數
(C) 階躍函數 (D) Sigmoid 函數

16. **Adaline 在學習權重時使用哪一種損失函數 (Loss Function)？**
(A) 二元交叉熵 (BCE) (B) 均方誤差 (MSE)
(C) 平均絕對誤差 (MAE) (D) 負對數概似 (NLL)

17. **梯度向量在某一點所指的方向為何？**
(A) 函數下降最快的方向 (B) 等高線的切線方向
(C) 函數上升最快的方向 (D) 指向原點

18. **若某權重目前為 2，損失對它的偏導數為 3，學習率為 0.1，經過一次梯度下降 (GD) 更新後的權重為何？**
(A) 0.3 (B) 2.3 (C) -0.3 (D) 1.7

19. **隨機梯度下降 (SGD) 每個 epoch 打亂樣本順序，主要目的為何？**
(A) 讓梯度重置為零 (B) 迫使標籤與特徵失去對應
(C) 減少固定順序造成的循環或順序效應 (D) 迫使標籤與樣本失去對應

20. **若 100 筆樣本以 batch size=20 的 mini-batch GD 訓練，完整一個 epoch 會更新幾次權重？**
(A) 5 次 (B) 20 次 (C) 100 次 (D) 2000 次

21. **某特徵的訓練平均值為 10、標準差為 2，則特徵數值 14 經過標準化 (Standardization) 後為何？**
(A) 1 (B) 2 (C) 7 (D) 14

22. **某特徵訓練集最小值為 10、最大值為 30，則特徵數值 15 經過正規化 (Normalization) 後為何？**
(A) 0.25 (B) 0.5 (C) 0.75 (D) 1.5

23. **邏輯回歸二元分類器若以輸出機率 $p \geq 0.5$ 判為類別 1，則當 net input $z = 0.3$ 時會預測為何類？**
(A) 類別 1 (B) 類別 0 (C) 類別 2 (D) 無法確定

24. **對單一樣本 $y = 1$，其二元交叉熵為 $-\ln(p)$。何者損失最小？**
(A) $p = 0.01$ (B) $p = 0.2$ (C) $p = 0.5$ (D) $p = 0.9$

25. **模型在訓練集上表現很好，但對未見過資料表現差，最符合何種現象？**
(A) 高變異的欠擬合 (B) 高偏差的欠擬合

(C) 高變異的過擬合　　(D) 高偏差的過擬合

26. **關於 L1 與 L2 正則化 (Regularization)，下列何者正確？**
(A) L2 一定使所有權重恰為零　(B) 兩者都會增加模型對極端權重的偏好
(C) L1 只處理資料缺失　　(D) L1 可產生零權重並用於特徵選取；L2 會縮小權重

27. **標準 5 折交叉驗證 (5-fold Cross-Validation) 中，每次使用幾折訓練、幾折驗證？**
(A) 1 折訓練、4 折驗證　　(B) 4 折訓練、1 折驗證
(C) 5 折訓練、5 折驗證　　(D) 2.5 折訓練、2.5 折驗證

28. **Stratified k-fold 的主要目的為何？**
(A) 保證每折的評估分數相同　　(B) 使每個特徵平均值恰為零
(C) 使每折大致保留原資料的類別比例　(D) 讓每折恰好只含一種類別

29. **網格中超參數 A 有 3 種值、B 有 4 種值，每組做 5-fold CV。若不計最後的 refit，以格狀搜尋 (Cross-Validation based Grid Search) 執行模型選擇，總共擬合幾次？**
(A) 60 次　(B) 12 次　(C) 48 次　(D) 35 次

30. **指定類別 1 為正類別 (Positive)。真實標籤為 1、模型卻預測為 0，應計入何者？**
(A) FP (偽陽)　(B) FN (偽陰)　(C) TP (真陽)　(D) TN (真陰)

---------- **以下題目 31-40 乃與 Python 程式語言基礎有關** ----------

31. **執行圖 1 中的程式碼後，螢幕上會印出什麼結果？**
(A) Grade A　(B) Grade B
(C) Grade C　(D) 程式會報錯

圖 1

```
score = 80
if score > 90:
    print("Grade A")
elif score > 80:
    print("Grade B")
else:
    print("Grade C")
```

32. **執行圖 2 中的程式碼後，螢幕上會印出什麼結果？**
(A) 1 2 3　(B) 1 2 2　(C) 1 2 1　(D) 1 2

圖 2

```
count = 1
while count < 3:
    print(count)
    count += 1
print(count)
```

33. **執行圖 3 中的程式碼後，螢幕上會印出什麼結果？**
(A) 15　(B) 0　(C) 6　(D) 10

圖 3

```
index = 0
for i in range(5):
   index += i
print(index)
```

34. **執行圖 4 中的程式碼後，螢幕上會印出什麼結果？**

(A) 87
87

(B) 87
86

(C) 86
86

(D) 程式會報錯

```
a = 86
def foo():
  a = 87
  print(a)

def bar():
  print(a)

foo()
bar()
```

圖 4

35. **執行圖 5 中的程式碼後，螢幕上會印出什麼結果？**

(A) 天氣預報: 晴天
天氣預報: 雨天, 降雨機率: 25%

(B) 天氣預報: 晴天, 降雨機率: 0%
天氣預報: 雨天, 降雨機率: 25%

(C) 天氣預報: 晴天, 降雨機率: 0%
天氣預報: 雨天, 降雨機率: 0%

(D) 程式會報錯，因為『weather_forecast("晴天")』少傳了一個參數

```
def weather_forecast(status, chanceOfRain=0):
    print(f"天氣預報: {status}, 降雨機率: {chanceOfRain}%")

weather_forecast("晴天")
weather_forecast("雨天",25)
```

圖 5

36. **Python 的串列支援切片 (Slicing) 操作，若有一個串列 numbers = [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]，執行 results = numbers[2:6] 後，numbers 的值為何？**

(A) [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]
(B) [2, 3, 4, 5]
(C) [2, 3, 4, 5, 6]
(D) [1, 2, 3, 4]

37. **承上題，results 的值為何？**

(A) [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]
(B) [2, 3, 4, 5]
(C) [2, 3, 4, 5, 6]
(D) [1, 2, 3, 4]

38. **執行圖 6 中的程式碼後，螢幕上會印出什麼結果？**

(A) 12
(B) 18
(C) 45
(D) 15

```
total = 0
matrix = [[1, 2, 3], [4, 5, 6], [7, 8, 9]]

for i in range(len(matrix)):
    for j in range(len(matrix[i])):
        if i == j:
            total += matrix[i][j]

print(total)
```

圖 6

39. **執行圖 7 中的程式碼後，螢幕上會印出什麼結果？**

圖 7

```
fruits = ["apple", "banana", "cat", "dog", "egg", "flower"]
print(fruits[4:0:-2])
```

(A) ['egg', 'cat']　(B) ['egg', 'cat', 'apple']　(C) ['dog', 'banana']　(D) ['flower', 'dog', 'banana']

40. **執行圖 8 中的程式碼後，螢幕上會印出什麼結果？**

(A) [1, 2, [86]]　(B) 程式會報錯（索引值超過範圍）

(C) [1, 2, 86]　(D) [1, 2, [86, 4]]

圖 8

```
list_A = [1, 2, [3, 4]]
list_A[2][0] = 86

print(list_A)
```

---------- **以下題目 41-50 乃與 scikit-learn 實作機器學習的完整流程有關** ----------

請根據圖 9 中的程式碼回答下列問題：

41. **第 1~9 列程式碼的目的為何？**

(A) 依序執行完整的模型選擇與評估　(B) 載入程式所需要的外部模組、型別與函式

(C) 宣告變數與函式名稱　(D) 單純是註解訓練流程，直譯器不會理會

42. **第 13 列程式碼的目的為何？**

(A) 將原始資料中標籤以外的所有特徵欄，轉換成 NumPy 的二維陣列

(B) 將原始資料中的標籤欄轉換成 NumPy 的一維陣列

(C) 將原始資料中標籤欄有缺失值的樣本丟棄後，將資料轉換成 NumPy 的二維陣列

(D) 將原始資料中標籤欄有缺失值的樣本丟棄後，將標籤欄轉換成 NumPy 的一維陣列

43. **第 15~16 列程式碼的目的為何？**

(A) 將類別型的文字標籤轉換成獨熱編碼　(B) 將類別型的數值標籤轉換成獨熱編碼

(C) 將類別型的文字標籤轉換成整數編碼　(D) 將類別型的數值標籤轉換成文字編碼

44. **第 18~20 列程式碼的目的為何？**

(A) 將資料集隨機切分成「訓練集 (20%)」與「測試集 (80%)」

(B) 將資料集隨機切分成「訓練集 (20%)」與「驗證集 (80%)」

(C) 將資料集隨機切分成「訓練集 (80%)」與「驗證集 (20%)」

(D) 將資料集隨機切分成「訓練集 (80%)」與「測試集 (20%)」

45. **第 23 列程式碼的目的為何？**

(A) 對特徵缺失值以完整的訓練集與測試集資料中該特徵的總體平均值補值

(B) 對特徵缺失值一律以測試集資料中該特徵的平均值補值

(C) 對特徵缺失值一律以訓練集資料中該特徵的平均值補值

(D) 訓練時對特徵缺失值以訓練集資料中該特徵的平均值補值，測試時對特徵缺失值則以測試集資料中該特徵的平均值補值

46. **第 24 列程式碼的目的為何？**

(A) 採用標準化特徵縮放　(B) 採用正規化特徵縮放

(C) 加入正則化避免過擬合　(D) 設定模型評估指標為標準尺度

47. **根據第 22~45 列程式碼，以格狀搜尋執行模型選擇時主要針對哪些超參數的組合？**

(A) 特徵選取演算法中使用到的估計器的學習率、分類器的學習率

(B) 特徵選取演算法中使用到的估計器的資料量、分類器的資料量

(C) 特徵選取演算法中使用到的估計器的批次大小、分類器的批次大小

(D) 特徵選取演算法中使用到的估計器的正則化強度、分類器的正則化強度

48. **根據第 22~45 列程式碼，以格狀搜尋執行模型選擇時採用的模型評估指標為何？**

(A) 正確率　　(B) 精確率　　(C) 召回率　　(D) F1 分數

49. **若第 51 列程式碼印出的混淆矩陣如下，且指定類別 1 為正類別。請問召回率是多少？**

```
[[68  3]
 [1  42]]
```

(A) 42/45　　(B) 68/69　　(C) 68/71　　(D) 42/43

50. **第 53 列程式碼的目的為何？**

(A) 計算所有 FP (偽陽) 樣本的索引位置

(B) 計算所有 FN (偽陰) 樣本的索引位置

(C) 僅找出第一個 FP (偽陽) 樣本的索引位置

(D) 僅找出第一個 FN (偽陰) 樣本的索引位置

```python
import numpy as np
import pandas as pd
from sklearn.model_selection import train_test_split, GridSearchCV, StratifiedKFold
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import LabelEncoder, StandardScaler
from sklearn.feature_selection import SelectFromModel
from sklearn.linear_model import LogisticRegression
from sklearn.pipeline import Pipeline
from sklearn.metrics import classification_report, confusion_matrix

df_text = pd.read_csv("wdbc_missing.csv")

X = df_text.drop(columns=['target']).to_numpy()
y_raw = df_text['target'].to_numpy()
label_encoder = LabelEncoder()
y_encoded = label_encoder.fit_transform(y_raw)

X_train, X_test, y_train, y_test = train_test_split(
    X, y_encoded, test_size=0.2, random_state=42
)

pipeline = Pipeline([
    ('imputer', SimpleImputer(strategy='mean')),
    ('scaler', StandardScaler()),
    ('feature_selection', SelectFromModel(
        LogisticRegression(l1_ratio=1.0, solver='liblinear', random_state=42)
    )),
    ('classifier', LogisticRegression(l1_ratio=0.0, max_iter=2000, random_state=42))
])
```

```python

param_range = [0.01, 0.1, 1.0, 10.0, 100.0]
param_grid = {
    'feature_selection__estimator__C': param_range,
    'classifier__C': param_range
}

cv_strategy = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
grid_search = GridSearchCV(
    estimator=pipeline,
    param_grid=param_grid,
    cv=cv_strategy,
    scoring='recall',
    refit=True,
    n_jobs=-1
)

grid_search.fit(X_train, y_train)
best_model = grid_search.best_estimator_
y_pred = best_model.predict(X_test)

print(confusion_matrix(y_test, y_pred))
print(classification_report(y_test, y_pred, target_names=label_encoder.classes_))
err_Index = np.where((y_test == 1) & (y_pred == 0))[0]
```

圖 9